

Q-Framework Development & Validation Whitepaper v1.0 RC1

異種混在型AI基盤のための計算状態仮想化・適応型フロー制御

2026年10月

本ホワイトペーパーは、実際に稼働しているシステムを記録したものである。

Q-Framework は、長時間の生成AIワークロードがコンシューマGPUの実用的なVRAM領域に近づいた場合でも、OOMを単純な終端とせず、計算状態を観測・制御・保存・復元・移動可能な資源として扱えるかを検証する異種混在型コンピューティング基盤です。

現在のシステムは lineage、checkpoint/resume、CPU/RAM-backed state、runtime control signal、QSTATIC、multi-node continuation、model-forward candidate working-set virtualization を持つ構成へ発展しています。

現在の証拠

公開可能な開発証拠には、cross-GPU state/hash verification、GPU→CPU/RAM→GPU rescue lineage、H3 model-forward 内の QmRNA candidate、exact FFN token chunking、CPU-only global streamed-attention reference と full attention の数値一致検証が含まれます。

単一22GB GPUで最新 full-length working-set virtualization を用いて最終15秒 H3 workload を production quality で完了した、という主張はまだ行いません。