

Q-Framework Development & Validation Whitepaper v1.0 RC2

異種混在型 AI 基盤における計算状態仮想化・適応型フロー制御・検証可能な継続計算

2026年10月7日

本ホワイトペーパーは、runtime evidence、SHA、state receipt を保持する実稼働システムを記録する。

Q-Framework は、複数 GPU を一つの巨大 GPU と見なす方式ではない。compute state、identity state、continuity state、execution lineage を単一 GPU の寿命から分離し、Freeze、Hash、Move、Restore、Resume、Branch、再検証を可能にする異種混在型 AI compute architecture である。

RC2 では CURRENT の実測記録に基づき、RC1 で十分に説明されていなかった四つの実行経路を追加する。

1. 設計原則

1. Logical state と physical residency を分離する。
2. GPU は execution worker であり、workload state の唯一の owner ではない。
3. Transport integrity と compute progression を別々に検証する。
4. 同じ lineage は resume も branch も可能である。
5. 公開 claim は runtime / SHA / receipt / measurable outcome に結び付ける。

2. 四つの検証済み実行経路

2.1 Mixed-GPU Stateful Continuation

250 MiB F-Block XCOPY では GPU0 VRAM → CPU/SharedMemory → GPU1 VRAM を実行し、source / Bridge RAM / target read-back の SHA-256 が完全一致した。

330674e23bf109a4f5e3983608ce118274373deae669e3d3bacee2f77639d5a6

bitwise_sha_match=true、round trip 約 3.6753 秒。

H3 rescue では seed 2609282350 が B0 checkpoint → CPU/RAM Bridge → B1 restore → sampler continuation → MP4 output まで完了し、output SHA は

307828DE5D0D54F36004EF9C97B2E4DAE5178E59A9C8EF74775F07522B788AB3

である。

Transport 中は SHA equality が integrity を示し、GPU が実際に compute を進めた後は新しい QREV / 新しい SHA が生成される。

2.2 Fixed-Owner Same-GPU Resume

qmrna_vvram_same_gpu は chain ごとに owner GPU を固定し、same_gpu_resume=true で continuation を行う。

共通 CHARACTER_ROOT seed、persistent Character Master、previous tail、checkpoint/result receipt、Dynamic Static を利用し、不要な migration を避ける。H3 ref0 は Character Master、ref1 は Static / previous tail / continuity context として扱われる。

Same-GPU Resume は locality を優先し、Mixed-GPU Resume は failover / shared-pool flexibility を優先する別モードである。

2.3 H3 Memory Static / QSTATIC Shared-State Compute

H3 state-block mapping では reproducible SHA を確認した。

- Audio reference latent: [1,32,2,40] / 10,240 bytes、同一 input repeat SHA 完全一致。
- Visual reference latent: 480×832、[1,24,1,52,30] / 149,760 bytes、repeat SHA 一致。
- Face reference visual block: Node A/A1 と Node B/B1 が同一 512×512 face reference から bit-identical SHA 1488ccf08323200643d5759046f2d47e1e16d44a70f278a79346aec53103d937 を生成。

Job268 では QRS0001 が 24 frames / 1s context を完了し、Face QC PASS (median 0.310109、minimum 0.245260、threshold 0.22)。その実出力から QW9 が dynamic_static_QRS0002.json を生成し、次の GPU segment がその後に dispatch された。

4-worker smoke では A0/A1/B0/B1 が branch 前に同一 authoritative identity/continuity state を SHA で確認し、その後別々の action/shot branch を実行できることも確認した。

2.4 Mixed-GPU Cross-File / Cross-Shot Stateful Compute

Shot XCOPY / Motion Bridge は、RGB final-frame のみを渡すのではなく Boundary Memory / QBlock を介して shot/file boundary を越える。

64 MiB cross-host test では B0 → Bridge → A1 GPU compute x+7 → Bridge → B0 restore を実行し、state integrity を確認した。

Job #135 / X1 では二つの別 boundary artifact :

- RS01 tail SHA D539AD5EAEA6B5BED4132A94CD24689AB4D4AD61142582894BF6DAD93290ED6B
- RS02 head SHA 1E51DBAAF8D30BAEBDB98D8393E82221FF1EEADAB93E2D9A50A7C100CFC444F4

を H3 が同時に conditioning として受け取り、B0 → PRE-OOM → A0 restore → output を完了した。
Smoke output SHA :

7A909C59636C1A18C6B1A1C7CD2037120F25DDC2C7F36CD2E62B4C70A43212E1

R3 は B0/A0/B1 間で s01→s20 を同一 lineage のまま進め、final artifact SHA :

C35FAECFE3C1BD0B5338CC4BE0EB8A854A10CE0FEEF86D39CA750DE6BB4A357C

を生成した。

3. Node + GPU / cross-environment solver consistency

HF_QWORKER_LITE V0.1 では、真の production sampler state に対して同じ arithmetic を :

- Utility01 (ComfyUI/PyTorch math path なし)
- H410 (ComfyUI math path なし)
- Node B PyTorch reference

で再実行した。

三者の recomputed-x SHA は完全一致 :

330271d14ee7086e27f875a4a56e720f169cdef1523e908ad94696bb70df15a4

source state に対する reverse→forward float32 reconstruction の max abs error は
4.76837158203125e-07、mean は約 2.03e-08。

これは universal bitwise GPU determinism の主張ではない。真の production state を元 runtime から分離し、別 node/runtime solver で同じ computed-result hash を再現できたという証拠である。

4. SHA の三つの意味

- **Exact Transport SHA:** state が変化していない場合 SOURCE = BRIDGE = TARGET。
- **Progressive QREV SHA:** 実際に compute が進めば SHA_n と SHA_{n+1} は変化する。
- **Cross-Environment Computed SHA:** 別 node/runtime が同一 arithmetic を実行して同一 computed hash を得る。

5. まだ主張しないこと

Unlimited VRAM、zero OOM、全 model への universal applicability、任意 GPU inference の universal bitwise determinism、22GB RTX 2080 Ti での最新 full-length 311-aligned H3 production PASS はまだ主張しない。

6. Disclosure boundary

公開：architecture、state lifecycle、smoke/runtime result、hash、receipt、benchmark methodology、sanitized interfaces。

非公開：production QmRNA pressure scoring、adaptive feed equation、page/residency selection、eviction/prefetch、Qvram serializer/restore order、Qsearch ranking、scheduler weight/fencing/retry authority、production streamed-QKV data-plane。

Open Specification • Open Evidence • Open Reference Interfaces • Closed Production Engine