Q-Framework × Temporal Möbius

異種 AI 計算の継続、ネイティブ生成、異種スーパーコンピュータ・ニューラルネットワーク技術白書

HAVEFUN AI Studio 技術研究開発
Q-Framework v1.0 RC4.3｜2026年10月25日｜日本語版
編集基準：RC4.3 繁体字中国語・統合レビュー版。RC4.2 の技術実績を保持し、単一 GPU の検証結果を追加。

> **証拠の取り扱い：**本書は、ネイティブ実行記録、条件を統制した比較試験、オーナーから報告されたが一次証跡の照合が未完了の成果、今後の研究目標を明確に区別する。異なるジョブ、解像度、GPU 数、フレーム数、ステップ数、シード、リトライ方針を同一条件の性能比較に流用しない。「RTX 2080 Ti 22GB」は、**VRAM を拡張した 22,528 MiB のカード**を指し、純正の 11GB 版ではない。

要旨：まず「単一 GPU で実行可能」を示し、その上で「複数 GPU で高速化」を検証する

HAVEFUN の Q-Framework は、4 基の GPU に作業を振り分けるだけのスケジューラではない。Foundation-00 の埋め込み型 Runtime Agent、MiniMax H3 の Sampler／DiT／Attention Hook、QmRNA による実行・VRAM 圧力管理、CPU／GPU 間の計算状態移送、Render Segment（RS）の時間分割、Temporal Möbius の数理的経路判断を組み合わせた技術体系である。長期目標は**異種スーパーコンピュータ・ニューラルネットワーク**の構築である。世代、性能、OS の異なる装置を、検証可能なタスク、再利用可能な計算状態、実行結果に基づく判断の更新によって協調させる。

現時点の技術成果には、**互いに異なる二つの実証軸**がある。

1. **単一 GPU の実行可能性。**VRAM を拡張した RTX 2080 Ti 22GB の A0／A1 環境で、MiniMax H3 のネイティブ動画生成を実際に実行した。Studio **#370**／**#371** は再生可能な短尺 MP4 を生成し、別途 A0 で **48 フレーム、24fps、14 Steps** の H3 実行が完了した。ジョブ **#365** は、**単一の A0** で 36 フレームの RS を10件順次処理し、最終的に **15 秒、360 フレーム** の MP4 を納品した。総時間は **3 時間 12 分 08 秒**。ネイティブ History には **9 回の CUDA OOM** があり、該当 RS 全体を新しい Prompt ID で再投入して成功した。つまり「単一 GPU による複数 RS の最終動画完成」であり、「360 フレームを一度にサンプリングした」「OOM が一度も起きなかった」という意味ではない。
2. **4 GPU の納品効率。**正式ジョブ **#361** では、独立した4基の RTX 2080 Ti 22GB（A0／A1／B0／B1）が H3 の10 RSを処理し、CPU が9か所の継ぎ目を編集した。出力は **15.000 秒、360 フレー**

ム、24fps、480×832、エンドツーエンドで **14 分 37 秒**。ネイティブ QmRNA Gate の接続は確認されているが、このジョブで QFREEZE や完全な QVRAM オフロード／リストアが発火したと推定することはできない。

特に意味のある**同一 GPU の対照試験**が 2026年10月4日に実施された。同じ A1 GPU、同じ Static 参照・シード、480×832、36 フレーム、24fps、10 Steps という設定で、**QmRNA Guard を使わないベースライン**は Step 1 で **PRE-OOM** 救済条件を検出し、所定の単独ワーカー MP4 を完成できなかった。一方 **QmRNA Pre-step Guard** を有効にした経路ではキャッシュを回収し、10 Steps を完了して MP4 を出力した。**PRE-OOM は事前保護条件であり、CUDA HARD_OOM の発生そのものではない。**この比較は、測定された負荷条件における「単一 GPU の実行可能性の違い」を示す。

オーナーからは**単一 GPU で H3 の 1080p 実行を完了した**との報告もある。本版ではこれを**達成報告／一次実行レシート未照合**として保持する。今後初めて着手する目標とは記さないが、第三者向けの定量主張に使う前に、ジョブ／Prompt ID、Sampler 本来の幅と高さ（後処理アップスケーリングとの区別）、フレーム数、時間、OOM History、成果物仕様、SHA を照合する必要がある。

代表的な実証結果

領域	実験・レシート	結果と適用範囲
GPU 間の計算継続	20 Steps：GPU0 の Step 1–10 → GPU1 の Step 11–20	対照と bitwise 一致、最大絶対差 0.0
計算状態の移送	約 250 MiB、GPU→CPU→SharedMemory／Bridge→GPU	送信元・Bridge・転送先の SHA-256 が一致
H3 ネイティブ制御	QmRNA Static Carrier、DiT、Sampler Hook	Checkpoint 間隔の実変更、`QMRNA_DIT_ENTER/EXIT`
QmRNA 同一 Seed 比較	22 フレーム、同じ参照と Seed	デコード済み 22/22 フレーム一致、単回の Sampler 窓は 81→76 秒
単一 GPU の短尺動画	#370／#371、A0	約 39 フレーム、16fps、2.437 秒の H3 MP4
単一 GPU の15秒納品	#365、A0	36フレーム×10 RS、9回のCUDA OOM後にRS再実行、計3:12:08
4 GPU の正式納品	#361、A0/A1/B0/B1	10 RS＋CPU 9継ぎ目、15秒／360フレーム、14:37
階層型メモリと停止・再開	Q7 CUDA、QFREEZE の統制試験	32 MiB CUDA 実体の退避／再ロードと Pause／Resume
Windows／Mac 協調	4 Windows Ollama、Mac LAN Math	実ノード対話、24/24 バッチの分散数値検証
重み学習	Möbius MLP、DistilGPT2 部分更新	それぞれ独立した重み更新記録

1. 技術的位置づけと基礎アーキテクチャ

1.1 GPU 数の増加より「計算の継続性」

従来の生成 AI ワークフローは、単一のモデル前向き計算、固定ワーカー、1基の GPU に常駐できる VRAM を実行単位とすることが多い。Q-Framework は、互換条件下で**計算状態**を識別、保存、ハッシュ照合、転送、復元、継続できるかを研究する。Temporal Möbius は依存関係、時間、利用可能な資源、過去の結果を数理的な経路選択に反映させる。

4基×22GB は総計約 **88GB の分散した物理 VRAM 資源**であって、**単一の連続した 88GB VRAM 空間ではない**。本研究の価値は、計算の分割・状態管理・時間軸の構成によって、従来の経路では完了困難な負荷を実行可能にし、分割可能な仕事の全体納品効率を高める点にある。

1.2 Foundation-00：Master と埋め込み Runtime Agent

Foundation-00 は、新しい4 GPU用 JSON や Studio の UI 制御より前に設計された基礎レイヤーである。Master が仕事・資源・方針を指示し、H3／ComfyUI 内の Runtime Agent が ModelPatcher、Sampler、Attention、DiT のネイティブ実行位置で制御を受け、検証可能なレシートを返す。

実装位置には `HFQmRNAGate`、`HFQmRNAStaticLoader`、`ModelPatcher.set_model_patch_replace`、`optimized_attention` および Sampler Hook が含まれる。#341 の GPU レシートには `gpu_model_gate_present=true`、`gpu_model_gate_match=true`、`gpu_workflow_receipt_verified=true` と記録されている。後発 UI の OFF 状態や Heartbeat 欠落だけを理由に、既存のネイティブ Q 系統が動作していなかったと判断してはならない。

1.3 実際の異種ノード構成

レイヤー	実体	確認済みの役割
Studio／Owner	HAVEFUN AI Studio	正式なジョブ指示、状態、成果物契約、納品
Production Master	Windows YUYU3D	スケジューリング、RS レシート、CPU 編集、MP4 検証
GPU Worker	Node A A0/A1、Node B B0/B1	独立した RTX 2080 Ti 22GB の H3 実行
CPU／Bridge	QWorker、Compute Bridge	分散数学、状態移送、SHA 照合、前後処理
Windows Möbius Brain	YUYU3D、Node A/B、Utility03	独立 Ollama 応答、ノード間の会話
Mac Möbius	iMac、M2、MacBook、追加 M1	LAN 行列分割、独立再計算、MLP／LLM 学習実験

現状の異種性は OS、CPU／GPU、役割の違いで実証されている。**異なる GPU 世代間で任意の H3 状態を汎用的に再開する機能**は、なお研究課題である。

2. Q-Framework：Foundation-00 と Q01–Q19 の技術系譜

QMobius と Temporal Möbius、QMater と QMaster の歴史的な呼称は維持する。ただし名称の違いだけで独立した2系統の計算エンジンが実証されたと見なさない。

索引	技術資産	機能・ネイティブ証拠
Foundation-00／Q13	埋め込み Runtime Agent	Master→ネイティブ Gate／Sampler／DiT→実行レシート
Q01	QmRNA Gate	制御信号を H3 に注入。#341 Gate の存在、適合、ワークフロー実行が確認済み
Q02	QmRNA Flag Control	Job／Seed／RS 別のチェックポイント・VRAM圧力方針。10/3 に `checkpoint_every=2→1`
Q03	QVRAM	GPU VRAM／CPU RAM／Bridge の階層化。250 MiB GPU間転送と独立した32 MiB CUDA退避試験
Q04	QSTATIC／Motion Static	参照フレーム、アンカー、状態情報。Static Carrier、デコード22フレーム比較
Q05	QFREEZE	保存可能な位置での停止と再開。B1の制御 CUDA Sampler Step 1→5
Q06	QAnswer／Finalizer	Checkpoint を Answer Packet として再利用。残り1 Stepのみを計算する統制実験
Q07	QSearch	Worker・結果・分岐・経路探索。4分岐完了記録
Q08	QRebuild	保存状態の数値 Tensor を再構成。PyTorch 正確 Roundtrip
Q09	QSTATE	Step、Seed、Tensor をハッシュ保存。Replica ACK、Bridgeアーカイブ
Q10	Temporal Möbius／QMobius	依存 DAG、資源・時間・リスクを考慮する候補経路判断
Q11	QMater／QMaster／RS	映像時間を追跡可能な Render Segment に分割して実行
Q12	FaceOff	人物 ID と顔品質の検証、特定 RS の再実行判断
Q14	Drip Feed	QKV／FFN の有界な分割実行。H3 ネイティブ `ffn_chunk=512`
Q15	Sampler Hook	ネイティブ Callback／Sampler の制御インターフェース
Q16	Master Message Transport	Job／Prompt／Worker／Event／ACK／Receipt の照合
Q17	CPU Frame Editor／PostEdit	CPU による継ぎ目編集、フレーム整合と MP4 検証
Q18	Mixed GPU／ノード間継続	A0→B0 CUDA 継続、GPU間数値一致、4 GPU RS生産
Q19	Studio Q-Framework Controls	オーナー操作、ディスパッチと表示。UI有効化だけでは実体実行の証拠ではない

派生コンポーネントには HF Compute Bridge／Motion Bridge、QWorker Lite、Streamed-QKV／Page Attention、QBLOCK／QLINEAGE／QREV、QBonus、Windows Möbius Brain、Mac Math Stream、Möbius Neural／LLM、Partner Node 認証、Network Map が含まれる。**インストール済み、ロード済み、ネイティブ実行済み、実測検証済み**は異なる段階である。

```
Studio / Director → Foundation-00 Master → Temporal Möbius 経路判断
  → RS コンパイル・QSearch / 適格 Worker 選択
  → QmRNA Gate / QSTATIC / H3 ネイティブ GPU
  → RS / QSTATE レシート
  → CPU Frame Editor / FFmpeg
  → 動画の長さ・フレーム・FPS・SHA・納品検証
```

3. 計算状態の継続：Tensor から H3 へ

3.1 20 Steps の決定論的な GPU 間継続

統制試験では GPU0 が Step 1–10 を計算し、CPU／RAM に数値状態を保存した後、GPU1 が Step 11–20 を実行した。結果は直接20 Steps を実行した対照と**bitwise identical**で、`max_abs_diff=0.0`。単に Prompt や画像を渡すのではなく、実際の数値計算状態を引き継いでいる。

3.2 約 250 MiB の実データ移送

2026年9月28日、**262,144,000 bytes（約250 MiB）**を GPU0 VRAM → CPU RAM → Windows Named Shared Memory → HF Compute Bridge → GPU1 VRAM と移動させた。送信元、Bridge、転送先の SHA-256 は一致した。

```
330674e23bf109a4f5e3983608ce118274373deae669e3d3bacee2f77639d5a6
```

元の CUDA Tensor を削除すると割り当てメモリがゼロになった。これは検証したバイト列の移送・整合性の証明であり、任意のモデルから見える「単一の88GB VRAM」が実装された証明ではない。

3.3 H3 のネイティブ状態復元とホスト間継続

X1／Motion Bridge には H3 の `RESTORE`／`SAMPLER_RESUME` イベントがある。別の受控経路では B0 checkpoint → B1 restore → H3 動画出力まで到達した。10月17日の Q7 では A0 が真の CUDA `HF_SAMPLER_STATE_V1` を保存し、Bridgeの複製と SHA を検証した後、B0 が読み込み、次の CUDA Step を計算した。任意の GPU モデル・モデル世代への完全互換を示すものではない。

4. QmRNA：モデル内部の制御を実証する

4.1 Static Carrier と Sampler の設定変更

10月3日、PNG iTXt `HF_QMRNA` Carrier を別ノードへ送り、SHA一致を確認。A1 Runtime が `QMRNA_CARRIER_LOADED` を記録し、`checkpoint_every` が実際に2から1へ変更された。後続の checkpoint と `QMRNA_COMPLETE` も残っている。CPU信号→Carrier→ネイティブGPU→Sampler挙動という連鎖が確認された。

4.2 H3 DiT のネイティブ Hook

10月6日、`QMRNA_DIT_ENTER/EXIT` を実 H3 モデル実行中に観測。隠れ特徴幅5,376、シーケンス長36,988、FFN Chunk 512 が記録された。単なるダッシュボード上の状態ではない。

4.3 同一 Seed A/B の測定

Sampler条件	ベースライン	QmRNA	単回の観測
8フレーム／4Steps／同Static・Seed	約34秒	約30秒	約11.8%短縮
22フレーム／10Steps／同Static・Seed	約81秒	約76秒	約6.2%短縮

22フレームについて MP4コンテナのSHAは異なるが、**デコード後22/22フレームのframemd5は一致**した。単回の比較であり、一般的な高速化率を保証しない。

4.4 PRE-OOM 前の VRAM 回収

強制 Guard のテストでは重い Step の前に残り VRAM **460–492MB**、キャッシュ回収後 **2,668MB**。22フレーム／10Stepsを完成させ、HARD_OOMは記録されなかった。キャッシュ削除と CUDA Tensor の真のオフロード／ロードは区別される。

4.5 Streamed-QKV の数値整合性

Online Softmax を用いる CPU 参考実装を 257 tokens ×4 heads ×32 head_dim で比較し、最大絶対誤差は約 **2.09×10^{-7}〜2.98×10^{-7}**、評価した分割パターンは `allclose` を満たした。H3 のすべての設定で数値同一性が確認されたわけではない。

5. QFREEZE／QVRAM／QSTATE／QAnswer／QRebuild

2026年10月17日の Q7 等では、複数の**別個の統制試験**が成立した。

- **同一 GPU Pause／Resume：**B1 CUDA マイクロ Sampler は Step 1 に `HF_QFREEZE_PAUSED` を記録し、再開して Step 5 に到達。

- **CUDAメモリ実体の解放と再ロード：**8,388,608個の float32、**33,554,432 bytes／32MiB** の Tensor を GPU→CPU／Bridge→GPU と移動。CUDA allocation は **33,554,432→0→33,554,432**。SHAが一致し次のCUDA計算が完了した。
- **QSTATE：**真の Sampler 状態、二つの Replica ACK、Bridgeアーカイブ、Master による遠隔 SHA 照合。
- **CPU QAnswer／QRebuild：**PyTorch による計算と `torch.save/load` の正確な往復。
- **ホスト間計算継続：**A0からB0へ状態を運び、B0上で次のCUDAステップを実行。

これらの機能が存在することと、#361／#365の各ジョブ中にそれぞれの機能が発動したことは同義ではない。

6. MiniMax H3：4 GPU 動画生産ライン

Node A／B は各2基の RTX 2080 Ti 22GB を備え、YUYU3D が Master・CPU編集・納品を担う。

Job／日付	処理経路	記録された成果
#135／9月29日	4 GPU H3／Bridge／Rescue	15.000秒／36fps／540フレームの動画とSHA
#243／10月4日	4 GPU の並列QRS	17 QRS完了、動画公開
#327／10月13日	4 GPU H3、7/7 RS	10秒・1080×1920に設定、MP4取得可、エンドツーエンド約1:55:44
#341／10月16日	元のQmRNA Gate、10/10 RS	ネイティブRS約11分18秒、Studio全体約34分18秒、OOMリトライあり
#344／10月17日	Möbiusの二島RSルート	10 RSと15秒／360フレームのMP4検証
#360／10月19日	4 GPU 10 RS＋CPU 9継ぎ目	15秒／360フレーム、**15分01秒**
#361／10月19日	**4 GPU 10 RS＋CPU 9継ぎ目**	**15秒／360フレーム、14分37秒**
T195／10月21日	各RS固有のPrompt SHA×10	10 RS、15秒／360フレームの出力

#361 Golden Baseline

台湾時間2026年10月19日 **23:07:24〜23:22:01** の **877秒**。GPUによるRS生成は23:21:07に完了。CPU側は9か所の編集を42.609秒で終了し、`gpu_invoked=false` と記録。最終成果物は H.264、**480×832、24fps、360フレーム、15.000秒**、デコード検証 PASS。

SHA-256：

```
a219bb7e78c0e4b0d74823c45d6b0458515583e351c785a686f5c56c424254d8
```

近接する #360 の901秒より24秒（2.66%）短い。GPU単体の演算カーネルの速度比較ではなく、制作フロー全体の実績である。

10月23日には PostEdit V2 により #365 の既存10 RSを再使用し、**360/360フレーム、24fps**の動画を再編した。元の映像との SSIM は **0.984182**、音声トラックなしの成果物も検証された。GPUを使った生成部分の再計算なしでCPU編集が可能となった例である。

7. Studio の5種類の制作モードと追加モデル

2026年10月20日の Studio **#368〜#372** は、それぞれネイティブ ComfyUI History と結果メディアを取得した。

モード	**Job・モデル・ノード**
Text-to-Image	#368／SDXL／B1
Image-to-Image	#369／SDXL／B1
Text-to-Video	#370／MiniMax H3／A0
Image-to-Video	#371／MiniMax H3／A0
Video-to-Video	#372／Wan VACE 1.3B／A0

370／#371は約39フレーム／16fps／2.437秒のネイティブ短尺動画であり、15秒の単発サンプリングと表現しない。後続実験にはQwen-Image-2512 FP8、Qwen-Image-Edit-2511 FP8、A0上のMiniMax H3 480×832／48フレーム／24fps／14Stepsがある。後者のGPU実行時間は約 549.31秒。#377ではオーナーによる画像編集成果の確認もあるが、モデル完走はあらゆる実用品質・人物ID保持の承認と同じではない。

8. Windows Möbius：複数の独立したAIノード

YUYU3D、Node A、Node B、Utility03の4台は独立したOllama応答と、Studio上の相互議論のレシートを残した。単純な算術問題で以前の14Bモデルの遅延が **66.186秒** だったのに対し、独立CPU-onlyのQwen2.5 3Bサービスではモデル応答 **1.094／1.265秒**、Studio側の作成から完了まで約 **4秒** が記録された。異なるモデルと構成による限定的な測定であり、全推論に一定倍率の改善があるとの主張ではない。

9. Mac Möbius：LAN数学分割と独立検証

- **iMac：**Teacher、入力生成、行列の前半128行を計算。
- **Mac mini M2：**Coordinator、後半128行と中央結果の統合。
- **MacBook Pro：**Evaluator、異なるアルゴリズムで行列全体を独立再計算。
- **Mac mini M1：**4台目のOwner Macとして32×256の追加分割を実行。

MOBIUS-MATH-001：256×256整数行列でM2とMacBookの最終SHA-256一致。

MOBIUS-MATH-002：実際のLAN配布・分算・返送・再計算を実施。3台の役割別計算時間は **895.542**／**578.363**／**2,646.046 ms**。役割が異なるため、単純な機種性能順位にはできない。

MOBIUS-MATH-STREAM-001：異なるSeed／Jobの **24/24バッチ VERIFIED**。第24バッチの合成結果と独立検証のSHA：

```
c8219ed9d202697cb93d771e8124d89d02e593fe8a297d89e80cda668cb88f57
```

M1も割り当てられた行列部分の計算・検証を実行している。4台がすでに任意の大規模AI学習を共同で実行できることまでは証明していない。

10. Temporal Möbius：数理的経路判断と実際の重み学習

10.1 ネイティブ結果から経路を推定

Windows World Model の履歴評価は実際の **41件**（Success 24、OOM 15、その他失敗2）を使用。時間順序を保持したテストで Brier Score **0.338335**、比較基準 **0.375438**。限定的なモデル評価として改善したが、全体最適を自律的に求める完成済みスケジューラとの証明ではない。

10.2 Möbius Neural：数理戦略MLP

5×12×3 のTanh／Softmax MLPで合成数学Kernelを選択。iMacが54件の訓練例を生成し、M2で**95Epoch**更新。Lossは **1.083127→0.098988**。MacBookの**未見24件**で正解率 **91.7%**、当該合成課題でNaiveとの時間比 **2.1161倍**。実際の重み変更と独立評価のレシートがある。

10.3 Möbius LLM：事前学習済みモデルの部分更新

M2 MPS上のDistilGPT2試験。総パラメータ **81,912,576**、訓練対象 **7,089,408**。合成学習42件・検証12件、16Steps、実行 **18.71秒**、Validation Loss **5.720391→5.176930**。28,362,810バイトの更新重みとSHAを記録した。これは部分重み訓練の実行証拠であり、汎用自律AI完成を意味しない。

11. Windows／macOSの異種協調が持つ意義

HAVEFUNが目指すのは、全機器に同じソフトを入れることではない。異なる計算役割を、ジョブID、状態、ネイティブレシート、独立検証で結ぶことである。WindowsはH3生成・GPU Hook・CPU編集・成果物契約、MacはLAN数学分割と学習実験など、それぞれ実体のある仕事を担う。

技術の主張は「2080 Tiの物理帯域がH100／H200になった」ではなく、**既存ハードウェアで完了できるタスクの範囲を広げる**ことであり、さらに完成率・品質・総時間・コストを踏まえた経路選択へ進む。

12. 検証方法と主な一次証跡

証拠方法	対応結果
数値完全性	GPU間20Steps `max_abs_diff=0.0`、Streamed-QKV誤差 約2〜3×10^{-7}
データ完全性	250 MiBの送信元・Bridge・転送先SHA一致
モデル実行	`QMRNA_DIT_ENTER/EXIT`、#341 H3 Gate Receipt
Callback	QAnswer Finalizerの残りStep実行
物理CUDAメモリ	32MiB Allocation 33,554,432→0→33,554,432
映像デコード	22/22フレームのframemd5一致
MP4契約	#361 15.000秒／360フレーム／24fps／480×832
CPU後編集	GPU再生成なしで9継ぎ目を処理。V2 360/360フレーム、SSIM 0.984182
Mac LAN計算	24/24バッチを独立検証
学習	MLP 95Epoch、DistilGPT2部分16Steps

個人画像、私的Prompt、認証鍵、顧客素材などは公開資料に含めない。

13. 結論：単一 GPU で「完了可能」にすることも技術成果

Q-Frameworkの意義は、単にGPUの配分を改善することではない。**従来の経路で失敗する高負荷の仕事を、既存の限られたハードウェアでどのように完了可能にするか**という研究である。単一の22GB RTX 2080 Ti による H3 実行、A1 の同条件 PRE-OOM 比較、#361 の4GPU短時間納品、状態継続、Macの分散数値検証と小規模な重み学習が、その異なる段階を示している。

Temporal Möbius の判断モデルは、**過去の実績→将来の候補経路予測→現在の資源・実行判断→実際の結果→判断の更新**というループを目指す。これは異種スーパーコンピュータ・ニューラルネットワークへの実践的な開発路線である。異種GPU世代をまたぐ一般的な復元、ネットワーク全体の継続学習、H100／H200との同条件性能優位は、今後検証すべき課題として明示する。

Q-Framework — Connecting Compute. Extending Possibility.

付録A｜公開技術資料

- 旧版公開白書RC3（日本語）
- Validated Execution Paths
- Public Claim Ledger
- Architecture Overview

付録B｜内部レシート対照索引

ジョブIDと資料種別のみを記載し、オーナーの写真・元Prompt・鍵・顧客データ・非公開ワークフローを公開しない。

- 状態移送：HF Compute Bridge F-Block XCOPY（2026/9/28）、Q7 Integration（10/17）。
- QmRNA／QSTATIC：10/3 PNG iTXt Carrier、10/4 A1 A/B、DiT Job #303、#341 Gate。
- H3動画：#135、#243、#327、#341、#344、#360、#361、#365、#370、#371、T195。
- Windows脳：10/15 Möbius Brain Chat、4ノードのOllama応答記録。
- Mac：MATH-001／002／STREAM-001、MOBIUS-EIGHT-001、NEURAL-001、LLM-001。
- CPU：HF_RS_POSTEDIT_V2_IMPLEMENTED（2026/10/23）。

付録C｜単一のRTX 2080 Ti 22GBにおけるH3実行能力

追加理由：RC4.2第6章は4GPU生産に重点があった。RC4.3は単一GPUの証拠を独立して整理する。ここでの「単一」は、H3のネイティブGPU推論がA0またはA1の1基だけで行われるという意味であり、CPU編集や通常のファイル転送を否定するものではない。

実験	ネイティブ実証	条件・制限
#370／#371	A0のH3 Text-to-Video／Image-to-Video	約39フレーム、16fps、2.437秒。15秒ではない
10/21の48フレーム	A0、480×832、24fps、14Steps、約549.31秒	2秒のネイティブ動画
#365	A0が36フレーム×10RSを順番に生成、最終15秒／360フレーム	3:12:08、9回のCUDA OOM後にRS再投入
#361（別実験）	4基のRTX 2080 Ti	8-Step条件が異なる。全体納品14:37

1080pの証拠ステータス：オーナーは単一22GB GPUでH3の1080p作業を完了したと報告している。これは「報告済み達成事項／対応する一次レシートの収集待ち」として残す。ジョブ、ネイティブ解像度、アップスケーリングの有無、フレーム数、時間、OOM履歴、FFprobe、SHAを照合するまでは、独立検証済み1080pネイティブ性能として公開しない。

付録D｜PRE-OOM未完了から同一GPUの完了へ

日付：2026年10月4日。**GPU：**A1 RTX 2080 Ti、VRAM 22,528MiB。**比較設定：**同Static／Seed、480×832、24fps、36フレーム、10Steps。

- **QmRNA Guardなし：**Step1の空きVRAMは**108MB**。ランタイムが `RESCUE_ARMED reason=PRE_OOM` を記録。単一ワーカーの所定MP4は生成されなかった。

- **QmRNA Guardあり：**Step1〜9の前に空きVRAMが**76〜140MB**まで低下したが、キャッシュ回収後に約**3,212〜3,244MB**となり、全10Stepsを完了して**188,242バイトのMP4**を生成。該当実行にHARD_OOMは記録されていない。
- **別のGuard試験：**22フレーム／10Stepsで空きVRAM **460〜492MB→2,668MB**、実行完了。
- **モデル内の実行記録：**DiTのENTER／EXIT、`ffn_chunk=512`。

適切な結論：測定された負荷では、Guardのない基準経路がPRE-OOM条件で単独完了できず、Guard導入経路が完了した。すべての未導入2080TiのH3タスクでCUDA HARD_OOMが必ず発生するという一般命題でも、Guardが永久にあらゆるOOMを防ぐという命題でもない。別途実証した32MiB CUDA退避がこのジョブで発動したとも断定しない。

付録E｜長期目標：異種スーパーコンピュータ・ニューラルネットワーク

1. **ネイティブ実行層：**Foundation-00／QmRNAがSampler、DiT、Attentionを制御する。
2. **状態とメモリ層：**QVRAM／QSTATIC／QSTATE／QFREEZEが検証可能な保存・転送・再ロード・継続を支援する。
3. **分散協調層：**QSearch／QWorker／RS／Compute Bridgeが単一GPU、4GPU、Windows／Macの異なるタスクを協調する。
4. **判断と学習層：**Temporal Möbiusが過去の結果から候補経路、リスク、時間、必要資源を評価し、実行結果により判断を更新する。

既に実証した範囲：QmRNAの同GPU比較、単一GPUのH3ネイティブ動画、#365の単一GPU 15秒（リトライを含む）、#361の4GPU生産、CUDA状態移送、MacのLAN数学、限定的なMLP学習。

汎用化が未検証の範囲：任意のGPU世代間のH3ネイティブ復元、ネットワーク全体の信頼性ある自律判断・継続学習、H100／H200との完全同条件の性能比較。

異種スーパーコンピュータ・ニューラルネットワークは、VRAMの総量だけでなく、**タスクを完了できるか、数値状態を検証できるか、判断が改善しているか、映像品質、納品時間、総資源コスト**によって評価されるべきである。