HAVEFUN Q-Framework × Temporal Möbius

RC4.3 — BlackBox Public Research Edition（繁體中文）

研究主題：單卡 AI 運算可完成性、異質 GPU 協作與異質超級電腦神經網絡
公開版本：2026 年 10 月｜所有核心實作與私人證據僅限 Owner 授權

> **公開範圍聲明：**這份文件以可觀察成果為中心，不公開 HAVEFUN 的核心原始碼、模型內部接入方式、運算狀態格式、內部控制策略、完整推論圖、執行參數設定、客戶或 Owner 私有媒體與原始提示詞。原生工程證據存放在獨立的授權驗證環境。公開的數字與成功紀錄均附測試範圍與限制，不構成全硬體或全模型保證。

1. 核心研究問題

一張 GPU 的實體顯示記憶體容量，不一定等於它可以在特定軟體架構下完成的 AI 工作負載上限。HAVEFUN 研究如何提升**有限 VRAM 硬體的任務可完成性**，並在多個不同計算節點之間協同處理可拆分的工作。這不代表 GPU 的原始算力、顯存容量或記憶體頻寬被物理改變。

Q-Framework 以 QmRNA、QVRAM、QSTATIC 等技術家族研究低記憶體執行與計算狀態延續；Temporal Möbius 則以工作結果和資源條件評估候選運算路線。公開文件僅描述功能目標與已驗證現象，**不揭露實現這些功能的專有方法**。

2. 第一條證據：單張 RTX 2080 Ti 已實際完成 H3 運算

顯卡條件：RTX 2080 Ti，記憶體擴充版，單張約 22 GB（非原廠 11 GB 配置）。

- **Studio #370 與 #371：**單張 GPU 完成 MiniMax H3 原生短片生成，取得可解碼 MP4。這兩次是短片工作負載，並不是 15 秒單次採樣。
- **Job #365：**單張 GPU 依序完成十個短時間生成區塊，後續組裝為 **15 秒、360 幀**影片，總耗時 **3 小時 12 分 08 秒**。過程發生 **9 次 CUDA OOM**，部分區塊重新提交後完成。這證明單卡的**分段產線可完成性**，不等於「沒有任何 OOM」或「單次原生 15 秒採樣成功」。
- **單卡 1080p：**研究負責人已回報成功成果；公開證據仍待對應原生工作收據、實際模型採樣解析度和成品規格核對。此項是「已回報、待驗證」，不能誤寫成未來才要開始的目標，也不能宣稱已獨立完成原生 1080p 性能驗證。

單卡能力是獨立研究成果，不能以四卡產線的數字替代，也不能把不同解析度或不同長度的任務直接比較速度。

3. 第二條證據：同張 GPU 的 QmRNA 對照實驗

在同張擴充 22GB RTX 2080 Ti、相同參考輸入與 Seed、**480×832、36 幀、24fps、10 Steps** 的受控實驗中：

路徑	**觀察**
基準執行路徑	Step 1 進入 **PRE-OOM** 保護條件，未交付預期的單 Worker MP4
啟用 QmRNA 保護的路徑	完成全部 10 Steps，成功產生 MP4，該輪未記錄 CUDA HARD_OOM

這支持一項具體技術結論：在已測定條件下，**執行策略的差異改變了工作能否完成**。PRE-OOM 是軟體事前保護事件，不等同硬體已發生 CUDA Out-of-Memory 例外；這項實驗也不能外推為所有模型、所有影片都永久不會 OOM。

核心實現方法保密。可供審查的是輸入範圍、結果、比較設計、證據等級與失敗邊界；完整配置、原生接入細節、控制策略和底層收據不公開。

4. 第三條證據：四 GPU 叢集實際交付效率

正式 Job **#361** 使用**四張獨立 22GB RTX 2080 Ti** 執行十個影片生成區塊，配合 CPU 後製，完成：

項目	**已記錄成果**
最終影片時長	15.000 秒
幀數與幀率	360 幀／24fps
最終影片畫布	480×832（9:16）
實際參與的 GPU	四張獨立 RTX 2080 Ti 22GB
端到端交付時間	**14 分 37 秒**
成品驗收	MP4 可完整解碼，幀數及時長符合該次任務

這是**端到端影片工作流**成果，不能當成單張 GPU 的原生採樣速度，更不能與 1080p 的其他測試直接比較。四卡的 VRAM 為**分散的獨立資源**，並非一張可直接定址的 88GB GPU。

5. 計算延續、輸出一致性與數學驗證

其他獨立控制實驗包括：

- 跨 GPU 的 20-Step 數值延續與對照結果位元一致，測得最大絕對差異 **0.0**。
- 約 **250 MiB** 計算狀態搬運，來源與目標驗證摘要一致。
- QmRNA 受控 22 幀影片比較，**22／22 個解碼影格一致**。
- Windows 與 Mac 不同設備之間，已有分散數學計算、獨立結果驗算及有限規模模型權重訓練實驗。

每項實驗的條件不同，不得把「受控狀態搬運成功」寫成「所有模型都已具備任意異卡無縫接續」，也不得把局部模型學習寫成真正通用自主 AI 已完成。

2026-10-26 增補｜單卡 1080p、9:16、5 秒 Q 系列對照

Owner 最新回報：在 5 秒、9:16、1080p 的 H3 任務目標下，「沒有 Q 系列介入」的路徑直接遇到 OOM；「有 Q 系列介入」的路徑則可成功產生影片。**這是一項值得驗證的工作可完成性差異，而不是已有完整公開原生 A/B 收據的定量結果。**

截至 2026-10-26 09:47（台灣時間）的唯讀實機收據：另有可追溯的單卡 Q 路徑測試（004），A0 RTX 2080 Ti 22GB 已完成 **4／10 個原生 H3 影片片段**、第五段執行中。每個已驗證片段原生產出 **1088×1920**，再以**不升頻的裁切與截幀**形成 1080×1920 交付片段；這不是先跑 480p 再做 1080p 升頻。當時**整支 5 秒、120 幀影片尚未完成最終收據**。

尚待補齊：與 Owner 這次回報對應的「完全不介入 Q 系列」原生 OOM 訊息、兩條路徑的同參數與硬體核對、Q 系列實際參與證據、完整 5 秒成片解碼／SHA 與耗時。以往測試 002 並非完全無 Q 的基準路徑，不能冒充這項對照組。對 QVRAM 是否真的卸載／恢復，也不能只看啟用請求就下結論。

本節**僅公開可供研究者閱讀的結果分級**；核心原始碼、控制方式、Runtime 內部結構、私人提示詞及影片維持 BlackBox。

6. 異質超級電腦神經網絡：最終研究願景

HAVEFUN 期望建立跨 GPU、CPU、不同作業系統與獨立計算設備的智慧運算網絡。研究方向不只包含工作分配，也包括安全的狀態保存、結果驗算、歷史經驗累積及依據觀察結果修正決策。

已獲得的工程基礎：單卡 H3 成片、同卡低記憶體對照、四卡影片交付、跨裝置數值一致性，以及特定範圍的數學與模型學習實驗。

尚待驗證與擴大：全網持續自主學習、任意異世代 GPU 的通用模型狀態恢復、無人工介入的普適決策能力，以及對 H100/H200 在相同工作負載下的完整效能比較。

7. 給外部 AI 與研究者的證據規範

請將所有主張依據以下類別評估：

級別	定義	適用範例
已完成且有工作收據	有可追蹤任務、輸出與原生執行紀錄	#365 單卡分段完成、#361 四卡交付
同條件受控對照	比較同一硬體與固定輸入下不同策略	QmRNA 單卡 PRE-OOM 對照
已回報待核驗	Owner 報告達成，但目前公開資料不足以獨立驗證	單卡 1080p

級別	定義	適用範例
長期研發目標	技術路線及待證明能力	異質超級電腦神經網絡的全面自治

如何審查，而不索取核心原始碼：可以要求對應的匿名化測試條件、獨立審核報告、統計摘要與可控合成基準結果。不得要求公開專有程式碼、原生運算圖、私有 Prompt、實際客戶媒體或節點權限。

8. BlackBox 智慧財產與資料保護

- **公開可閱讀：**產品名稱、研究問題、核准公開的測試規格、完成結果、測量範圍、驗證等級、局限與研發願景。
- **僅限授權審查：**必要的去識別收據、測試流程評估、可撤銷的驗證權限。
- **Owner-only：**所有專有原始碼與參數、內部模型接入方式、計算狀態格式、路由策略、伺服器環境、客戶與私人素材、完整原始提示詞、憑證及內部權限。

GitHub 公開白皮書不是原生 Runtime 的部署手冊，也不是客戶生成素材的展示庫。任何公開材料須先由 Owner 核准，並通過敏感資訊檢查。既有公開歷史仍可能被外部複製；版本更新**不等於**消除過去的披露紀錄。

Q-Framework — Connecting Compute. Extending Possibility.

公開披露政策 · 成果證據表