HAVEFUN Q-Framework × Temporal Möbius

RC4.3 — BlackBox Public Research Edition（繁體中文）

研究主題：單卡 AI 運算可完成性、異質 GPU 協作與異質超級電腦神經網絡
公開版本：2026 年 10 月｜所有核心實作與私人證據僅限 Owner 授權

> **公開範圍聲明：**這份文件以可觀察成果為中心，不公開 HAVEFUN 的核心原始碼、模型內部接入方式、運算狀態格式、內部控制策略、完整推論圖、執行參數設定、客戶或 Owner 私有媒體與原始提示詞。原生工程證據存放在獨立的授權驗證環境。公開的數字與成功紀錄均附測試範圍與限制，不構成全硬體或全模型保證。

1. 核心研究問題

一張 GPU 的實體顯示記憶體容量，不一定等於它可以在特定軟體架構下完成的 AI 工作負載上限。HAVEFUN 研究如何提升**有限 VRAM 硬體的任務可完成性**，並在多個不同計算節點之間協同處理可拆分的工作。這不代表 GPU 的原始算力、顯存容量或記憶體頻寬被物理改變。

Q-Framework 以 QmRNA、QVRAM、QSTATIC 等技術家族研究低記憶體執行與計算狀態延續；Temporal Möbius 則以工作結果和資源條件評估候選運算路線。公開文件僅描述功能目標與已驗證現象，**不揭露實現這些功能的專有方法**。

2. 第一條證據：單張 RTX 2080 Ti 已實際完成 H3 運算

顯卡條件：RTX 2080 Ti，記憶體擴充版，單張約 22 GB（非原廠 11 GB 配置）。

- **Studio #370 與 #371：**單張 GPU 完成 MiniMax H3 原生短片生成，取得可解碼 MP4。這兩次是短片工作負載，並不是 15 秒單次採樣。
- **Job #365：**單張 GPU 依序完成十個短時間生成區塊，後續組裝為 **15 秒、360 幀**影片，總耗時 **3 小時 12 分 08 秒**。過程發生 **9 次 CUDA OOM**，部分區塊重新提交後完成。這證明單卡的**分段產線可完成性**，不等於「沒有任何 OOM」或「單次原生 15 秒採樣成功」。
- **2026-10-26 單卡 1080p 正式成片：**單張記憶體擴充版 RTX 2080 Ti 22GB，10／10 支原生 1088×1920 H3 RS 成功，無升頻裁切並組成 **1080×1920、5 秒、120 幀、24fps MP4**；本輪**零 CUDA OOM 紀錄**、總耗時 **1 小時 39 分 16 秒**。已驗證成片規格與完整性，視覺品質待 Owner 驗收。這是分段生成後組片，不是單次 120 幀採樣。

單卡能力是獨立研究成果，不能以四卡產線的數字替代，也不能把不同解析度或不同長度的任務直接比較速度。

3. 第二條證據：同張 GPU 的 QmRNA 對照實驗

在同張擴充 22GB RTX 2080 Ti、相同參考輸入與 Seed、**480×832、36 幀、24fps、10 Steps** 的受控實驗中：

路徑	**觀察**
基準執行路徑	Step 1 進入 **PRE-OOM** 保護條件，未交付預期的單 Worker MP4
啟用 QmRNA 保護的路徑	完成全部 10 Steps，成功產生 MP4，該輪未記錄 CUDA HARD_OOM

這支持一項具體技術結論：在已測定條件下，**執行策略的差異改變了工作能否完成**。PRE-OOM 是軟體事前保護事件，不等同硬體已發生 CUDA Out-of-Memory 例外；這項實驗也不能外推為所有模型、所有影片都永久不會 OOM。

核心實現方法保密。可供審查的是輸入範圍、結果、比較設計、證據等級與失敗邊界；完整配置、原生接入細節、控制策略和底層收據不公開。

4. 第三條證據：四 GPU 叢集實際交付效率

正式 Job **#361** 使用**四張獨立 22GB RTX 2080 Ti** 執行十個影片生成區塊，配合 CPU 後製，完成：

項目	**已記錄成果**
最終影片時長	15.000 秒
幀數與幀率	360 幀／24fps
最終影片畫布	480×832（9:16）
實際參與的 GPU	四張獨立 RTX 2080 Ti 22GB
端到端交付時間	**14 分 37 秒**
成品驗收	MP4 可完整解碼，幀數及時長符合該次任務

這是**端到端影片工作流**成果，不能當成單張 GPU 的原生採樣速度，更不能與 1080p 的其他測試直接比較。四卡的 VRAM 為**分散的獨立資源**，並非一張可直接定址的 88GB GPU。

5. 計算延續、輸出一致性與數學驗證

其他獨立控制實驗包括：

- 跨 GPU 的 20-Step 數值延續與對照結果位元一致，測得最大絕對差異 **0.0**。
- 約 **250 MiB** 計算狀態搬運，來源與目標驗證摘要一致。
- QmRNA 受控 22 幀影片比較，**22／22 個解碼影格一致**。
- Windows 與 Mac 不同設備之間，已有分散數學計算、獨立結果驗算及有限規模模型權重訓練實驗。

每項實驗的條件不同，不得把「受控狀態搬運成功」寫成「所有模型都已具備任意異卡無縫接續」，也不得把局部模型學習寫成真正通用自主 AI 已完成。

2026-10-26｜單卡 1080p H3：原生高解析 RS 與完整 5 秒成片均已成功

正式實測：單張擴充至 22GB 的 RTX 2080 Ti，已經完成 MiniMax H3 的 1080p 等級原生高解析度影片運算，並交付完整 5 秒 MP4。 本次使用 Q 系列輔助的單卡執行路徑；有原生 RS 運算、媒體規格與成片雜湊完整性的獨立收據。

項目	**經核對的單卡成果**
GPU	**RTX 2080 Ti 22GB 擴充版 ×1**（不是原廠 11GB 版）
原生 MiniMax H3 RS	**10／10 支成功**；每支原生生成 **1088×1920、22 幀**
正式交付	**1080×1920、9:16、5.000 秒、24fps、120 幀 MP4**
解析度處理	只裁切並截幀（每 RS 交付 12 幀）；**沒有升頻**
本輪 CUDA OOM	**0 次紀錄**
整體耗時	**1 小時 39 分 16 秒**
驗證	十支原生 RS 成功回執、最終影片規格及雜湊完整性驗證；**視覺品質仍待 Owner 驗收**

因此本成果同時證實：**(1) 單張 2080 Ti 可完成原生 1080p 等級 H3 RS 運算；(2) 同張卡的分段運算可完成真正的 1080×1920、5 秒成片。**原生片段的 1088×1920 是 GPU 真正生成的解析度；交付 1080×1920 是無升頻裁切。這不是把低解析度影片升頻，也不是一次單獨採樣完整 120 幀。

嚴格區分：影片的 5 秒是播放長度，**不是 5 秒內運算完成**；本輪共耗時 1 小時 39 分 16 秒。「本次未記錄 OOM」不代表所有模型永久不 OOM。Q 系列輔助路徑成功不等於已獨立證實任何單一 QVRAM 卸載／恢復機制的因果作用。Owner 另回報未啟用 Q 的相關 H3 工作 OOM，仍待配對其原始失敗收據。

BlackBox：僅公開數值、範圍與成果級別。內部模型接入、演算法、私有素材、原始 Prompt、客戶資料與完整控制策略皆不公開。

6. 異質超級電腦神經網絡：最終研究願景

HAVEFUN 期望建立跨 GPU、CPU、不同作業系統與獨立計算設備的智慧運算網絡。研究方向不只包含工作分配，也包括安全的狀態保存、結果驗算、歷史經驗累積及依據觀察結果修正決策。

已獲得的工程基礎：單卡 H3 成片、同卡低記憶體對照、四卡影片交付、跨裝置數值一致性，以及特定範圍的數學與模型學習實驗。

尚待驗證與擴大：全網持續自主學習、任意異世代 GPU 的通用模型狀態恢復、無人工介入的普適決策能力，以及對 H100/H200 在相同工作負載下的完整效能比較。

6A. 多節點異質運算計劃（Multi-Node Compute Roadmap）

目的：讓 Temporal Möbius 在 Owner 授權下協調 Windows／macOS、GPU／CPU 與不同型號硬體，使數學推理、影音分段生成、成果驗算、學習回饋等工作能依能力分配。**本章描述工程路線圖，不等於整套八節點影音原生推論已完成。**

架構：一個計劃，三類職責

職責	公開功能與預期成果	狀態
Master／調度層	接收授權任務、拆成可驗證子工作，依資源條件派送並蒐集回執，保留 Owner 暫停／取消／回滾控制	已有多卡影片產線證據；跨主機統一調度持續整合
Brain／推理與品質層	使用不同 macOS 裝置執行數學、推理、候選策略比較與結果評分；目標逐步擴至四台 Brain	分散數學與有限訓練實驗已進行；常態閉環尚未全面驗證
Windows／GPU＋CPU Worker 層	依設備能力接受單段 H3 或其他可切分任務、回報狀態與結果；目標逐步擴至四台 Windows Worker 主機	四張 GPU 的特定影片產線成功；跨主機通用 Worker 協定仍在驗證

目標配置：四台 macOS Brain ＋ 四台 Windows Worker 主機，總計八台異質裝置。這是目標設備數，**不是已驗證八機同步運算，更不是八張 GPU 或單張 88GB 顯卡。**既有四卡交付是四張各自獨立的 22GB RTX 2080 Ti 協作，與未來八主機拓樸不同。

工作閉環：以回執證明每一步

`Owner 授權 → Master 拆解／派工 → Brain 評估 + Worker 執行 → 分段回執與一致性驗算 → CPU／GPU 成片 → 品質評分／失敗回饋 → 下次任務決策`

- 每一工作單元都需可追蹤 **Task／RS 識別、節點狀態、完成或失敗、耗時與可驗證輸出**；對外僅公開聚合後的匿名證據。
- 調度與恢復目標包含心跳、逾時偵測、重試冪等、防重複領取、不同裝置相容性及離線復原；**這些是驗收要求，不宣稱現已普遍實現**。
- QmRNA／QVRAM／QSTATIC／QAnswer 與 Temporal Möbius 分工可合作，但私有狀態格式、記憶體調度與模型接入方式仍為 **BlackBox Owner-only**。
- 系統不得擅自把未授權設備加入運算；授權、停止、回滾及證據保留均受 Owner 控制。

分階段工程里程碑

階段	驗收重點	公開證據級別
P0 已完成的基礎	單卡 1080p／5 秒完成，#361 四 GPU 480p／15 秒交付，受控數學與狀態一致性實驗	**已驗證特定工作負載**
P1 一台跨主機 Worker 閉環	身份相容、領題、實算、提交結果、回執、心跳、失敗回復及獨立重驗	**進行中的整合目標**
P2 八裝置擴展	四 Brain＋四 Windows Worker 的可見在線狀態、分流、負載測量、節點隔離與回退	**計劃，待實機全鏈驗收**
P3 自主驗算與學習	每次學習後自動生成隔離 Smoke、Master／Möbius 評分、比較輸出品質與速度，形成回饋閉環	**研究計劃；不可當成通用 AI 已完成**
P4 公開基準驗收	同任務下公開成功率、各節點耗時、失敗／OOM 次數與成果一致性	**待資料核驗後發佈**

衡量準則：先確認能否完成，再衡量時間與效率。完整的跨主機調度、GPU 原生計算跨異卡任意接續，以及全網自主學習能力，目前不得用既有四卡影片成功案例代替證明。

公開多節點架構頁與圖像：Multi-node architecture · 公開計劃。所有原始節點名稱、位址、Worker 連線方式、鑑權資訊及私人生成素材不公開。

7. 給外部 AI 與研究者的證據規範

請將所有主張依據以下類別評估：

級別	定義	適用範例
已完成且有工作收據	可追蹤任務、原生執行與最終影片完整性收據	**2026-10-26 單卡 1080p／5 秒／120 幀／10 RS**；#365 單卡分段成片；#361 四卡交付

級別	定義	適用範例
同條件受控對照	比較同一硬體與固定輸入下不同策略	QmRNA 單卡 PRE-OOM 對照
已回報待核驗	Owner 對照觀察仍缺原始失敗收據配對	**未啟用 Q 的 H3 OOM 對照**（不是已核驗的單卡 1080p 成片）
長期研發目標	技術路線及待證明能力	異質超級電腦神經網絡的全面自治

如何審查，而不索取核心原始碼：可以要求對應的匿名化測試條件、獨立審核報告、統計摘要與可控合成基準結果。不得要求公開專有程式碼、原生運算圖、私有 Prompt、實際客戶媒體或節點權限。

8. BlackBox 智慧財產與資料保護

- **公開可閱讀：**產品名稱、研究問題、核准公開的測試規格、完成結果、測量範圍、驗證等級、局限與研發願景。
- **僅限授權審查：**必要的去識別收據、測試流程評估、可撤銷的驗證權限。
- **Owner-only：**所有專有原始碼與參數、內部模型接入方式、計算狀態格式、路由策略、伺服器環境、客戶與私人素材、完整原始提示詞、憑證及內部權限。

GitHub 公開白皮書不是原生 Runtime 的部署手冊，也不是客戶生成素材的展示庫。任何公開材料須先由 Owner 核准，並通過敏感資訊檢查。既有公開歷史仍可能被外部複製；版本更新**不等於**消除過去的披露紀錄。

Q-Framework — Connecting Compute. Extending Possibility.

公開披露政策 · 成果證據表