HAVEFUN Q-Framework × Temporal Möbius

RC4.4｜BlackBox 公開研究白皮書・繁體中文審閱稿

2026 年 10 月 30 日｜由 RC4.3 帶狀增補，不覆寫歷史成果
核心命題：使受限 VRAM 的 GPU 執行原生 4K H3 運算而不發生 CUDA OOM；並驗證同一工作區塊可由異質節點共同計算、合併、恢復。

> **公開範圍與版本狀態**：這是供 Owner 審閱的 RC4.4 草稿，而非已核准的正式公開版本。所有技術主張依據已保存的試驗收據分級；不公開原始碼、私有模型接線、內部位址、憑證、控制參數、原始影像與客戶媒體。測試時觀測「沒有 OOM」不能自動外推為所有工作負載永遠不會 OOM。

版本摘要：RC4.4 的真正重點

本版維持 RC4.3 已驗證的單卡 1080p、四 GPU 影片交付和 QmRNA 對照成果，新增 **2026 年 10 月 30 日**原生 4K DiT／QKV 長跑與觀測、跨 GPU 同 Block 分食合併、QSTATIC／QFREEZE 狀態驗證、故障節點接手、1024×N DRIP 與 OOM 異卡路由修補。

首要驗收目標是 4K 計算本身是否避免 CUDA OOM，並且在長時間原生 H3 計算期間能留存進度。 影片最終輸出、畫面品質和跨節點端到端加速是不同層次的證據，**不應拿「尚未交付新影片」否定已完成的 4K 計算與分算實驗**。反之，部分分塊測試通過也不能假稱「整個 4K 工作已全部完成」。

證據層級	本版判定方式
A｜已交付並核驗	原生運算與可解碼媒體、尺寸／時長／雜湊等相符
B｜實機技術測試 PASS	真實 GPU 張量、真 H3 權重或原生擷取輸入；有合併／差異／簽章收據，但非完整影片
C｜原生 4K 執行觀測	對應 Job 的實際 Sampler／DiT／QKV 記錄、顯存與故障事件；不要求先完成 MP4
D｜程式修補／隔離驗證	源碼修正與單項測試通過；仍需區分是否已載入正式長跑程序
E｜待整合驗收	已有現成能力，但指定原生 Job 的整合、復原或比較尚無完整收據

1｜研究問題：不是增加實體顯存，而是提高任務可完成性

單張 RTX 2080 Ti 的實體容量和原始算力不會因軟體改變。HAVEFUN Q-Framework 探索的是：在有限 VRAM 下，透過 QmRNA、QVRAM、QSTATIC、QFREEZE、QAnswer 與 Temporal Möbius 的**既有協同機制**，使較大模型與較高解析度的運算可被安排、分頁、檢查、接手與完成。重點依序是**不 OOM／可恢復／結果正確**，其後才比較速度、吞吐和能耗。

Temporal Möbius 不等於多張顯卡固定分工。相同 Job → RS → Sampler Step → DiT Block 之內，還能將 Query／Key-Value 範圍切為更小的可驗證子片；有授權的裝置可以中途加入或離開，使用既有 Master 身分、租約與 QSTATIC 回執交接。這是已有分項實測的技術主線，**不是 RC4.4 新創建的另一套系統**。

2｜RC4.3 既有實證完整保留

歷史成果	工作負載及觀察	限制
單卡 1080p H3，2026-10-26	RTX 2080 Ti 擴充 22GB，10／10 原生 1088×1920 RS；交付 1080×1920、5 秒、120 幀 MP4；該輪 0 CUDA OOM；總耗時 1 小時 39 分 16 秒	分段再裁切組片，沒有升頻；非一次原生 120 幀 Sampler；視覺 QC 另計
單卡 #365	10 個 RS 串行組成 15 秒、360 幀，3 小時 12 分 08 秒	曾有 9 次 CUDA OOM 並重送相關 RS，不是零 OOM 成果
四卡 Gold #361	4 張 RTX 2080 Ti＋CPU 接縫，15 秒、360 幀、480×832，端到端 14 分 37 秒	不能將四卡 VRAM 當作單張直接定址 88GB
QmRNA 同卡 A/B	480×832、36 幀、10 Steps：參考路徑 PRE-OOM；QmRNA Guard 路徑完成 MP4	PRE-OOM 是事前保護，不等於 CUDA HARD OOM
受控一致性	20 Steps 跨 GPU 位元一致、約 250 MiB 狀態傳輸比對、22／22 畫面一致	各為特定測試，不代表所有模型任意續算
T245 真 4K 歷史成果	單卡原生 4K 等級 RS01（2176×3840 原生），裁切交付 2160×3840、12 幀、0.5 秒片段，原片與 Gold 副本雜湊一致	RS01 成功不代表整個原 Job 所有 RS 都已完成
ENG172／T248 QFREEZE	單卡原生 H3 480×832、5 幀、2 Steps，冷恢復剩餘運算並輸出可解碼 MP4	是小型原生恢復實證，不可直接當作 4K T259 同點恢復完成

關鍵：真正有必要拿來比較的，是同硬體、同原生模型、同解析度、同 Steps、同輸入與相同時間窗口的 CUDA OOM 事件、峰值 VRAM、有效計算秒數與正確性；不同影片長度的端到端時間不能當作直接的硬體性能比。

3｜RC4.4 新增：真正 H3 Attention 的同 Block 跨 GPU 分食

已存在且經實測通過的基線包含跨卡 KV 分工、同一個真 H3 Block 的 Q 分片、可合併的穩定 softmax 統計量，以及 Master 獨立驗算／簽章與原生候選消費。新版本將這些既有事實正式納入公開證據分類。

測試	內容	可公開的結果
ENG166｜真權重雙節點分工	兩張 GPU 使用一致的 MiniMax H3 權重和可重建測試輸入，分別算不同 KV 子區間，再合併局部 m/z/u	合併 PASS；受控誤差級別約 7.63×10^{-6}；測試輸入為確定性合成 X
ENG206／207｜真 H3 原生抓取	原生影片擷取 825 token 的 H3 RoPE 輸入，同一 Block 由 B0 計算 Q0–415、B1 計算 Q416–824	825／825 Query 合併 PASS；Master 抽樣 312 點 max-abs 約 6.00×10^{-7}；Ed25519 簽章，A1 隔離原生 Attention／out_proj 消費 PASS
ENG213｜分 KV 的穩定合併	真 H3 已套 RoPE 的 QKV，825 Queries × 56 heads × 128 維，共 5,913,600 個輸出值	m/z/u 合併 PASS；max-abs 約 6.56×10^{-6}、RMSE 約 2.16×10^{-7}；本項不是新 GPU 全程計算或正式 Sampler 接線
2026-10-30 真 H3 分工驗證	B0、B1 各處理相異 Query 範圍，Master CPU 另抽查 200 點	825 Query 完整覆蓋，max-abs 約 6.51×10^{-7}，Ed25519 簽章核驗通過；屬獨立技術驗證

上述結果證明同一計算 Block 可以在已驗證條件下跨 GPU 拆成更小的工作並合併驗證，**並不要求把完整 Block 永久綁定單一顯卡**。但特定 4K T259 原生 Sampler 尚未全面啟用這些候選並持續消費，不能把小規模 PASS 擴寫為「整部 4K 影片已跨節點完成」。

4｜RC4.4 新增：2026-10-30 原生 4K H3 長跑與無 OOM 研究

主要目標：原生 H3 4K 的 QKV／DiT 長時間計算可以繼續運作、避免 CUDA HARD OOM。 影片輸出不是本輪 Smoke 的首要通過條件；前台應以真實 GPU 工作、原生 Sampler／QKV 事件、監控時間戳和 CUDA 錯誤紀錄為主，而不是只靠是否已有成片。

本日有單卡原生 4K 工作依原 T245 技術條件運行：原生約 **2176×3840、22 幀、8 Sampler Steps**，分別在 A0 與 B1 進行驗證；修復後可觀察 QKV_STREAM、DiT Block 進度、FFN 分塊、實際 GPU 活動和 VRAM 使用。不同的 4K Job 應以各自 Prompt、硬體與實際事件獨立記錄。

重要範圍差異：10 月 30 日曾存在一筆修補前的 B1 原生 H3 CUDA OOM 記錄；其後調整原有 Gate／DiT 路徑，才有新的 4K 長跑觀測。不能把前筆 OOM 刪去，也不能因此否定修復後在 4K QKV 階段**未觀測到新的 CUDA OOM**的有效運算區間。A0 曾有監控器 timeout 中斷，但原生 QKV／GPU 活動持續出現；timeout 不是 CUDA OOM，必須分別歸類。

4K 核心觀測項目	本日成果／狀態
原生高解析度	2176×3840 等級、22 幀、8 Steps 的 H3 真實 QKV／DiT 工作已啟動

4K 核心觀測項目	本日成果／狀態
修補後 GPU 原生運作	既有正式程序記錄 QKV_STREAM、DiT Block、FFN／QKV 分頁與 GPU 活動；相關時段未觀測新 OOM
VRAM 壓力管理	依各 Job 實測顯存與分頁追蹤；不把預防性 PRE-OOM、監控 timeout 或節點斷電混同 CUDA HARD OOM
成功標準	**4K 原生有效計算區間，無 CUDA HARD OOM 且計算狀態可追蹤**；需以有起訖時間及完整錯誤日誌的收據核實整段聲明
非本輪必要條件	最終 MP4 交付；其後可作獨立成果與影像 QC，但不阻擋單項無 OOM 判定

因此，**RC4.4 不再把「沒有新成片」當作原生 4K 計算的失敗條件**。對外發表時應明確載明所觀測的時間範圍、發生／未發生 CUDA OOM 的工作區間及所用硬體，避免宣稱「所有 4K 作業必然不 OOM」。

5｜RC4.4 新增：QSTATIC／QFREEZE 同 Job 狀態延續與故障復原

Möbius 的研究目標不是把中斷事件當作計算全部歸零。原有機制能以 Job／RS／Step／Block／Q-KV 子片描述進度，檢查可驗證的最後安全邊界，在不同授權節點上接續必要工作。**游標是一種定位，不是張量快照；真正可恢復的內容必須能驗證與載入。**

10 月 30 日的 T259 B1 工作遭遇實際主機斷電。原工作保留了 4K QKV 頁面游標及工作身份；舊規劃 8 Steps × 50 Blocks × 224 Q 頁 × 224 KV 頁為 **20,070,400 個規劃 QUE 位置**。偵測到的位置約在 **193 萬個 QUE 序號**附近，這不能直接當作全部已完成或已有可恢復的張量。

今日新增實證：同一工作的 A1 新補算分支建立 Step0 QSTATE，冷儲存大小約 **21.95 MB**；Node B 既有 Compute Bridge 核對完整檔案 SHA 與大小，CPU 可解讀真實 Sampler 狀態。另有兩份副本 ACK，達成所記錄的 D3 保存級別。B1 的 RTX 2080 Ti 也已真實載入狀態張量至 CUDA，再搬回 CPU 比對內容完整，往返約 **278 ms**。這證明真實新生計算狀態可以跨節點保留並由另一 GPU 載入，**但不是說斷電前 B1 精確中斷點的快照已被找回**。

復原能力	已知證據與界線
斷電定位	既有 QKV 游標及原 Job 身分保存，能逆向對應規劃 Step／Block／頁面；不等於中斷張量本身已持久化
新生 QSTATE	A1 新建 Step0 原生狀態可讀、SHA 比對及雙副本成功
異卡 GPU 重新載入	B1 GPU 對該新生狀態完成 CUDA 真載入與 SHA 一致性檢查
同一原 Job 自動完成接續	仍須有有效租約、必要原生 Sampler 消費及後續工作回執；本日尚未宣稱全鏈 PASS

6｜RC4.4 新增：Worker 動態 JOIN／LEAVE 與節點自我復原

在原有 QSTATIC／QAnswer 接棒測試中，三個 Worker 的動態承接、租約到期重派、拒收重複提交及拒收未授權 Worker 均已有驗證記錄。同一 Block 內 Q／KV 子片也有 0／1／2 GPU 加入的隔離實驗；它證明可以拆分和合併，不等於任何小型測試都必然比單機更快。

10 月 30 日另外有一項**現役 Node B 自動恢復**：兩張 GPU 的 ComfyUI Worker 曾離線，原 watchdog 在確認 Resource Manager 無任務、無租約及資源空閒後，修正既有的 FREE＋OFFLINE 自啟條件。原 Worker 復原到 ONLINE／IDLE，兩卡佇列可查。這是**實際節點服務自動恢復 PASS**，不同於該節點已完成新的 4K 分片運算。

7｜RC4.4 新增：1024×N DRIP、HARD OOM 異卡候選與速度導向派工

沿用既有 QmRNA／Compute Bridge／Master 的工程，DRIP 頁面規模以 **1024×N** 表達動態候選，而非僵化限制在特定固定頁數。10 月 30 日原始碼已增加候選處理及策略檢查，但活動中的部分原生程序仍有既存頁面上限，**未經安全邊界及正式程序重載不得假稱新策略已在現役 4K Job 全面生效**。

另外修正既有 OOM 接手邏輯：確認為 **CUDA HARD OOM** 時不把工作重新派回剛 OOM 的同一張卡；須先確認可信 SHA、有效冷狀態／副本、資源管理器的真空閒與合法候選，再考慮從其他節點復原。對正常主動轉移，Möbius 應根據同類原生工作配對數量、時間、複製與網路成本及可靠性選擇預期較快的節點；不能用低工作量小分頁的表面 QUE/s 誤當真正性能提升。

本日結果屬原程式修補、隔離路由測試 PASS。 由於既有活動中的 Bridge／Sampler 未任意中斷重載，還不能宣稱正式 Job 已完成一次 HARD OOM 自動異卡轉生。RC4.4 將它列為技術增補與待整合驗收，不會混為已交付成片。

8｜驗證規範：4K「沒有 OOM」究竟如何成立

優先指標 P0 — 4K 原生計算可持續且無 CUDA HARD OOM。 一個有效的無 OOM 實證區間需具備對應原生 Job 的起訖時間、實際進入 Sampler／DiT／QKV 的事件、VRAM 遙測、錯誤記錄與中斷分類；非 OOM 的斷電、人工停止、網路中斷或 timeout 應單獨歸類。若僅取得某時刻的 `queue_running`，只能說當時有運行，不能替代整個時間窗的錯誤檢查。

次要指標 P1 — 能在必要時 Freeze／恢復／異地接手。 分別驗證有效原生狀態、核驗摘要、跨節點載入、租約與回收，以及原生 Sampler 是否消費答案；不因某一環節缺乏證據便否認已驗證的分算與恢復能力。

指標 P2 — 多卡比單卡有可重現的速度收益。 僅在同任務、同模型、同輸出、相同驗證範圍下比較端到端耗時、CPU/GPU空轉與通訊成本。**最後成片與視覺品質屬可獨立驗收的 P3，不是本次 P0 的前置條件。**

9｜BlackBox、來源與對外公開界線

- **公開：**原生負載種類、硬體級別、必要的分塊規模、觀測結果、相對誤差、歷史成功與本日待驗差距。
- **僅限核准評估：**去識別的執行收據與量測方式，經 Owner 同意後方可審查。
- **Owner-only：**原生 Hook、模型接入、計算狀態格式、完整路由／安全設定、私有工單、憑證、客戶媒體與原始提示詞。

本白皮書的依據是 HAVEFUN 權威 CURRENT／TEST CURRENT 的既存實測記錄及其對應原始收據索引，並對照 RC4.3 公開白皮書與 Claim Ledger；**本審閱稿並未額外重跑 GPU 測試，也不聲稱取得更新後的影片或現場 Owner QC**。所有已核驗 Gold 基線維持有效，所有未完成研究與正式整合項目繼續累加。

HAVEFUN Q-Framework — Connecting Compute. Extending Possibility.

版本說明：RC4.4 審閱稿｜2026-10-30｜繁體中文｜公開供 Owner 審閱，不代表已核准為正式定稿。