# HAVEFUN Q-Framework × Temporal Möbius

## 我們正在重新定義 AI 運算的未來

### 如果有一天，AI 不再受限於一張顯卡，世界會變成什麼樣子？

想像一下。

一家動畫工作室，花了十幾個小時生成一段影片，卻因為顯卡記憶體不足，整個工作突然中斷，只能從頭再來。

一家企業，為了導入 AI，被迫不斷採購更昂貴的伺服器與 GPU。明明舊設備還能正常運作，卻因為跟不上新模型的需求，只能提前淘汰。

又或者，世界各地有大量電腦，每天都有運算資源閒置，卻因為規格不同、地點不同，無法一起完成一項 AI 工作。

**我們認為，這些問題不應該成為人工智慧發展的宿命。**

於是，我們從台灣開始，挑戰一個長期被視為理所當然的觀念：

**AI 要變得更強大，就一定得依賴越來越昂貴的硬體嗎？**

我們的答案是：不一定。

這正是 **HAVEFUN Q-Framework × Temporal Möbius** 誕生的原因。

**如今，我們已經把答案做出來：結合防止 OOM 與運算重生的技術成果，真正的原生 4K AI 影片已經成功產生。**

不只是讓模型開始計算。

**而是讓原本容易中斷的高解析度 AI 工作，走到真正的影片交付。**

---

## 第一個突破：VRAM 不是 AI 的牆，它只是一個工具

當整個產業持續追逐 RTX 4090、RTX 5090 等新世代高階 GPU，原生高解析度 AI 影片生成仍可能受到顯存容量與執行方式的限制。為了讓工作完成，許多生成流程只能犧牲解析度，或者依賴更昂貴的硬體。

**我們決定走另一條路。**

我們沒有從最昂貴的 GPU 開始。

我們選了一張 **2018 年問世的 RTX 2080 Ti**。它保留舊世代 GPU 的運算架構，我們使用的版本經過記憶體擴充，約有 22GB VRAM。

然後，我們讓它完成了：

- **原生 1080p 影片生成。** 單張 RTX 2080 Ti 完成 MiniMax H3 原生高解析度運算，交付 1080 × 1920、5 秒、120 幀的影片；沒有低解析度升頻，該次執行未記錄 CUDA OOM。
- **原生 4K AI 影片已成功產生。** 我們已用真實 MiniMax H3 原生運算完成 **4K 等級、2176 × 3840 的 MP4 影片輸出**，沒有用低解析度升頻冒充。這不再只是「4K 能不能跑」的討論，而是已經有真正的原生影片成果。
- **多 GPU 協同完成影片。** 四張 RTX 2080 Ti 與 CPU 協作，曾以 **14 分 37 秒**完成 15 秒、360 幀的 AI 影片。

我們不是要證明 2080 Ti 比新顯卡更快。新一代 GPU 有它們強大的硬體優勢。

我們要證明的是：

**決定 AI 工作能否完成的，不應該只有顯存大小；運算的方法，同樣可以改寫硬體的能力邊界。**

一張舊卡都能做到。

**換成你的卡呢？**

對產業而言，這不只是多了一個技術選項，而是多了一條不必永遠靠硬體升級來擴張 AI 能力的道路。

對企業而言，這是重新思考硬體投資的起點。

對創作者而言，這是讓 AI 創作能力逐漸回到自己手上的機會。

**我們要讓已經存在的每一張卡，發揮它真正的價值。**

---

## 第二個突破：運算重生（Compute Rebirth）

但是，我們不打算停留在解決記憶體不足。

我們開始思考一個更大的問題：

**為什麼一項運算工作，一定要和執行它的那張顯卡共存亡？**

運算可能持續數小時。一次 OOM、當機或突然斷電，卻可能使前面投入的時間與成本付諸流水。

我們要改變的，就是這件事。

**Compute Rebirth——運算重生。**

顯卡可以被理解為運算的「身體」。

當原本的身體無法繼續工作，我們要讓運算的「靈魂」能夠在另一台合格設備上醒來，延續原本的工作。

這不只是想像。我們已經取得跨設備運算與恢復研究的具體成果：

- **跨設備接續運算：最大數值差異 0.0。** 在受控接續實驗中，跨設備運算與未中斷的參考結果達到完全一致。
- **真實 AI 模型跨 GPU 協作：最大絕對誤差僅約 $7.63 \times 10^{-6}$。** 我們讓不同 GPU 使用真實模型權重共同完成計算，並以實測確認合併結果的高度一致性。
- **跨設備運算重生，接續完成原生 4K 影片。** 真實 H3 工作已經歷跨設備狀態移交、原生恢復與接續運算，最終產生可驗證的原生 4K MP4。對我們而言，「重生」不再只是漂亮的概念，而是走向實際影片成果的技術能力。

**原生 4K 影片已經誕生，這就是我們突破 OOM 與推進運算重生最有力量的答案。**

這些成果讓我們看到，運算不必永遠被鎖在原來的那張 GPU 裡。

**我們不只要讓 OOM 不發生。**

**我們更要讓 OOM 發生之後，運算還能繼續。**

這不只是故障排除，而是重新定義 AI 運算的生命週期。

**當硬體倒下，運算的價值不應跟著消失。**

---

## 第三個突破：讓世界各地的電腦，成為同一個運算網路

如果一張顯卡不再是運算工作的唯一依靠，下一個問題就出現了。

為什麼一定要把所有 GPU 放在同一間機房？

為什麼不同世代、不同規格、不同地點的設備，不能共同完成 AI 工作？

**我們已經開始回答這個問題。**

Temporal Möbius 的研究，已經取得跨 GPU 分工、運算結果驗證、節點接力，以及不同類型運算工作協作的成果。

我們要讓不同設備不必擁有一模一樣的規格，也能依照自身能力，成為整體運算網路的一部分。

快的設備多貢獻一些算力。

舊設備也能承擔適合自己的工作。

一台電腦離線，不必代表整個系統失去工作的可能。

這就是我們正在建立的：

### Heterogeneous Compute Network——異質算力網路

未來，授權加入的企業設備、工作站、資料中心與其他算力資源，可以透過同一個運算服務體系共同創造價值。

**我們要改變的，不是每一台電腦有多強，而是全世界的電腦能不能一起變得更強。**

當算力能夠跨越硬體與地域，資源閒置就不再只是成本問題。

它將成為一個值得重新開發的市場。

---

## 我們看到的，不只是一項技術，而是新的產業機會

我們已經開始規劃 Q-Framework 的技術授權、企業運算服務，以及分散式算力平台。

AI 影片生成，只是第一個讓大家看見成果的舞台。

**真正值得關注的是：誰能改變 AI 算力的成本結構，誰就有機會改變整個產業的商業模式。**

### Technology Licensing｜技術授權

對硬體製造商與 AI 軟體業者，我們提供延伸既有產品價值的技術合作機會。

讓原本受限的硬體承擔更多 AI 工作，讓軟體技術成為產品競爭力的一部分。

### Compute as a Service｜算力即服務

對企業而言，真正重要的不是租用了多少 GPU 時間，而是投入多少成本，能夠可靠地完成多少 AI 工作。

我們要把運算完成能力、資源使用效率與運算延續性，轉化為企業願意購買的服務。

### Heterogeneous Compute Network｜異質算力平台

對算力提供者，我們要創造讓閒置資源參與市場的新途徑。

當分散的運算資產能夠共同提供服務，算力就不再只是一筆設備成本，也能成為創造收入的資源。

**我們不只是想讓 AI 運算更便宜。**

**我們想讓每一份已經存在的算力，都能創造更大的價值。**

## 從台灣出發，挑戰 AI 算力的既定規則

我們不是要否定更強大的 GPU。

更強大的晶片，當然能推動 AI 發展。

但我們相信，AI 的下一次重大改變，不一定只來自更昂貴的硬體，也可能來自重新定義「運算如何存在」的技術。

我們選擇了一條不同的道路。

不是要求世界不斷淘汰舊設備，才能迎接新的 AI 模型。

而是透過我們的發明，讓既有硬體擁有更長的價值生命，讓運算不再輕易因故障而失去成果，讓分散各地的算力開始彼此連結。

我們已經用真實硬體、真實 AI 模型與跨設備運算，**讓原生 4K AI 影片成功產生**，將這條道路從想像帶進實際成果。

現在，我們要把它推向更大的市場。

**我們不只是突破硬體限制。**

**我們要讓運算跨越硬體，讓算力跨越地域，讓 AI 的可能性不再被單一設備決定。**

*HAVEFUN Q-Framework × Temporal Möbius*

### Beyond OOM. Beyond Hardware. Beyond Boundaries.

讓每一份算力，都創造更大的價值。