HAVEFUN Q-Framework × Temporal Möbius

我們正在重新定義 AI 運算的未來

如果有一天，AI 不再受限於一張顯卡，世界會變成什麼樣子？

想像一下。

一家動畫工作室，花了十幾個小時生成一段影片，卻因為顯卡記憶體不足，整個工作突然中斷，只能從頭再來。

一家企業，為了導入 AI，被迫不斷採購更昂貴的伺服器與 GPU。明明舊設備還能正常運作，卻因為跟不上新模型的需求，只能提前淘汰。

又或者，世界各地有大量電腦，每天都有運算資源閒置，卻因為規格不同、地點不同，無法一起完成一項 AI 工作。

我們認為，這些問題不應該成為人工智慧發展的宿命。

於是，我們從台灣開始，挑戰一個長期被視為理所當然的觀念：

AI 要變得更強大，就一定得依賴越來越昂貴的硬體嗎？

我們的答案是：不一定。

這正是 **HAVEFUN Q-Framework × Temporal Möbius** 誕生的原因。

第一個突破：VRAM 不是 AI 的牆，它只是一個工具

當整個產業持續追逐 RTX 4090、RTX 5090 等新世代高階 GPU，原生高解析度 AI 影片生成仍可能受到顯存容量與執行方式的限制。為了讓工作完成，許多生成流程只能犧牲解析度，或者依賴更昂貴的硬體。

我們決定走另一條路。

我們沒有從最昂貴的 GPU 開始。

我們選了一張 **2018 年問世的 RTX 2080 Ti**。它保留舊世代 GPU 的運算架構，我們使用的版本經過記憶體擴充，約有 22GB VRAM。

然後，我們讓它完成了：

- **原生 1080p 影片生成。** 單張 RTX 2080 Ti 完成 MiniMax H3 原生高解析度運算，交付 1080 × 1920、5 秒、120 幀的影片；沒有低解析度升頻，該次執行未記錄 CUDA OOM。
- **原生 4K 影片片段。** 我們已完成真實 H3 原生 4K 運算與可驗證片段，不靠升頻冒充高解析度。
- **多 GPU 協同完成影片。** 四張 RTX 2080 Ti 與 CPU 協作，曾以 **14 分 37 秒**完成 15 秒、360 幀的 AI 影片。

我們不是要證明 2080 Ti 比新顯卡更快。新一代 GPU 有它們強大的硬體優勢。

我們要證明的是：

決定 AI 工作能否完成的，不應該只有顯存大小；運算的方法，同樣可以改寫硬體的能力邊界。

一張舊卡都能做到。

換成你的卡呢？

對產業而言，這不只是多了一個技術選項，而是多了一條不必永遠靠硬體升級來擴張 AI 能力的道路。

對企業而言，這是重新思考硬體投資的起點。

對創作者而言，這是讓 AI 創作能力逐漸回到自己手上的機會。

我們要讓已經存在的每一張卡，發揮它真正的價值。

第二個突破：運算重生（Compute Rebirth）

但是，我們不打算停留在解決記憶體不足。

我們開始思考一個更大的問題：

為什麼一項運算工作，一定要和執行它的那張顯卡共存亡？

運算可能持續數小時。一次 OOM、當機或突然斷電，卻可能使前面投入的時間與成本付諸流水。

我們要改變的，就是這件事。

Compute Rebirth——運算重生。

顯卡可以被理解為運算的「身體」。

當原本的身體無法繼續工作，我們要讓運算的「靈魂」能夠在另一台合格設備上醒來，延續原本的工作。

這不只是想像。我們已經取得跨設備運算與恢復研究的具體成果：

- **跨設備接續運算：最大數值差異 0.0。** 在受控接續實驗中，跨設備運算與未中斷的參考結果達到完全一致。
- **真實 AI 模型跨 GPU 協作：最大絕對誤差僅約 7.63×10^{-6}。** 我們讓不同 GPU 使用真實模型權重共同完成計算，並以實測確認合併結果的高度一致性。
- **中斷後的運算恢復：已取得原生 AI 工作的實際恢復成果。** 我們不只研究如何在故障前避免中斷，也持續把跨設備接棒能力推向完整的高解析度生成工作。

這些成果讓我們看到，運算不必永遠被鎖在原來的那張 GPU 裡。

我們不只要讓 OOM 不發生。

我們更要讓 OOM 發生之後，運算還能繼續。

這不只是故障排除，而是重新定義 AI 運算的生命週期。

當硬體倒下，運算的價值不應跟著消失。

第三個突破：讓世界各地的電腦，成為同一個運算網路

如果一張顯卡不再是運算工作的唯一依靠，下一個問題就出現了。

為什麼一定要把所有 GPU 放在同一間機房？

為什麼不同世代、不同規格、不同地點的設備，不能共同完成 AI 工作？

我們已經開始回答這個問題。

Temporal Möbius 的研究，已經取得跨 GPU 分工、運算結果驗證、節點接力，以及不同類型運算工作協作的成果。

我們要讓不同設備不必擁有一模一樣的規格，也能依照自身能力，成為整體運算網路的一部分。

快的設備多貢獻一些算力。

舊設備也能承擔適合自己的工作。

一台電腦離線，不必代表整個系統失去工作的可能。

這就是我們正在建立的：

Heterogeneous Compute Network——異質算力網路

未來，授權加入的企業設備、工作站、資料中心與其他算力資源，可以透過同一個運算服務體系共同創造價值。

我們要改變的，不是每一台電腦有多強，而是全世界的電腦能不能一起變得更強。

當算力能夠跨越硬體與地域，資源閒置就不再只是成本問題。

它將成為一個值得重新開發的市場。

我們看到的，不只是一項技術，而是新的產業機會

我們已經開始規劃 Q-Framework 的技術授權、企業運算服務，以及分散式算力平台。

AI 影片生成，只是第一個讓大家看見成果的舞台。

真正值得關注的是：誰能改變 AI 算力的成本結構，誰就有機會改變整個產業的商業模式。

Technology Licensing｜技術授權

對硬體製造商與 AI 軟體業者，我們提供延伸既有產品價值的技術合作機會。

讓原本受限的硬體承擔更多 AI 工作，讓軟體技術成為產品競爭力的一部分。

Compute as a Service｜算力即服務

對企業而言，真正重要的不是租用了多少 GPU 時間，而是投入多少成本，能夠可靠地完成多少 AI 工作。

我們要把運算完成能力、資源使用效率與運算延續性，轉化為企業願意購買的服務。

Heterogeneous Compute Network｜異質算力平台

對算力提供者，我們要創造讓閒置資源參與市場的新途徑。

當分散的運算資產能夠共同提供服務，算力就不再只是一筆設備成本，也能成為創造收入的資源。

我們不只是想讓 AI 運算更便宜。

我們想讓每一份已經存在的算力，都能創造更大的價值。

從台灣出發，挑戰 AI 算力的既定規則

我們不是要否定更強大的 GPU。

更強大的晶片，當然能推動 AI 發展。

但我們相信，AI 的下一次重大改變，不一定只來自更昂貴的硬體，也可能來自重新定義「運算如何存在」的技術。

我們選擇了一條不同的道路。

不是要求世界不斷淘汰舊設備，才能迎接新的 AI 模型。

而是透過我們的發明，讓既有硬體擁有更長的價值生命，讓運算不再輕易因故障而失去成果，讓分散各地的算力開始彼此連結。

我們已經用真實硬體、真實 AI 模型與跨設備運算，將這條道路從想像帶進實測。

現在，我們要把它推向更大的市場。

我們不只是突破硬體限制。

我們要讓運算跨越硬體，讓算力跨越地域，讓 AI 的可能性不再被單一設備決定。

HAVEFUN Q-Framework × Temporal Möbius

Beyond OOM. Beyond Hardware. Beyond Boundaries.

讓每一份算力，都創造更大的價值。